


עיבוד שפה טבעית – תרגיל 4

אליה חסון 208845032, שיר שבח 322407701

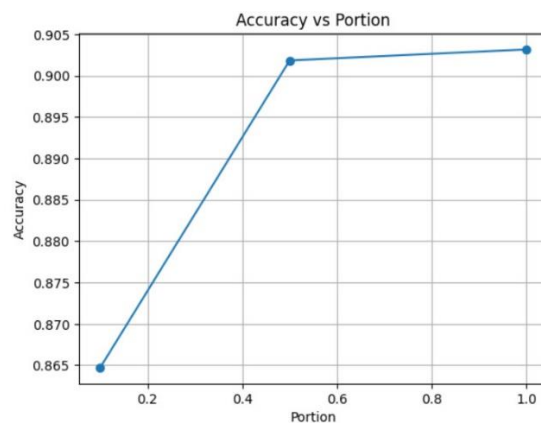
1. תוצאות הרגרסיה הלוגיסטית:

```
Logistic regression results:  
Portion: 0.1  
accuracy: 0.7261273209549072  
Portion: 0.5  
accuracy: 0.8090185676392573  
Portion: 1.0  
accuracy: 0.8262599469496021
```



2. תוצאות Transformer fine-tuning:

```
Finetuning results:  
Portion: 0.1  
accuracy: 0.8647214854111406, loss: 0.36542072892189026  
Portion: 0.5  
accuracy: 0.9018567639257294, loss: 0.3906078338623047  
Portion: 1.0  
accuracy: 0.903183023872679, loss: 0.44057756662368774
```



3. תוצאות zero-shot:

Zero-shot result:
0.771220159151193

4.

א. ניתן לראות כי המודל שהפיק את מידת הדיוק הגבוהה ביותר עבור test set הוא Transformer fine-tuning. עבור $\text{portion}=1$, נקבל את מידת הדיוק ~ 0.903 .

ב. במודל הרגרסיה הלוגיסטית ניתן לראות כי המעבר בין $\text{portion}=0.5$ ל- $\text{portion}=1$ הוא רגיש יותר, עליה של ~ 0.017 , בהשוואה למודל Transformer fine-tuning ששם העלייה קטנה יותר, של ~ 0.002 .

ג.

i. יתרונות zero-shot:

1. גמיש וניתן להכללה: מודל zero-shot נועד להבין הקשרים בין מושגים במובן הרחב, ניתן להשתמש בו למגוון רחב של משימות מבלי להזדקק לדאטה נוסף ספציפי לכל משימה.
2. אין צורך ב-training data ספציפי למשימה: מודל ה-zero-shot יכול לבצע חיזויים עבור משימות שלא אומן עליהם באופן מפורש עם תגיות, מה שיכול להיות נוח מאוד כאשר אין מספיק מידע מתויג.

ii. חסרונות zero-shot:

1. הכללה גסה: מודל zero-shot עשוי להיות לא רגיש לניואנסים ספציפיים של כל משימה. מכיוון שהוא עורך תחזית מבוססת על ידע כללי, ייתכן שהוא לא יתפוס מורכבויות או משימות הדורשות הבנה מעמיקה.
2. דיוק נמוך בהשוואה למודלים האחרים – ניתן לראות שהמודל zero-shot קיבל דיוק נמוך בהשוואה למודלים הקודמים שבדקנו בתרגיל זה. ייתכן כי זאת בגלל שהמודל מתבסס על מידע קודם לגבי יחסי המחלקות שאינו תמיד קיים או מדויק למשימה הנוכחית.